项目介绍书 · PROJECT PROSPECTUS

Clinical FaultBench

面向医疗 AI 智能体的失效审计基准:在坏数据、坏工具、坏时序下,系统性度量临床大模型智能体的失败方式、错误传播与不确定性表达。不只测它能不能做对,更测它怎么失败。

医疗 AI 智能体失效审计基准 · 方案冻结 v1.0 · 2026 年 10 月

一、项目概述

> ClinicalFaultBench 给临床 AI 智能体做"混沌工程":不只测它能不能做对,更测它在坏数据、坏工具、坏时序下怎么失败、失败如何传播、失败时敢不敢承认。

基于大语言模型的临床智能体正在进入电子病历导航、医嘱审查、出院随访等真实工作流,但行业现有评测几乎全部在"理想输入"下进行。本项目构建一个面向临床失效模式的审计基准:以 MIMIC-IV 纵向病程数据为任务底座,通过一个对被测方完全透明的故障注入代理层(FaultProxy),把"看起来合理但错"的临床数据缺陷注入智能体的输入与工具环境,系统度量其决策错误率变化、错误传播、患者安全违规与不确定性表达能力。

立项理由有三:

1. 踩在公认开放问题上。2026 年 npj Digital Medicine 等期刊将"自适应智能体的临床验证缺口"列为该领域头号未解问题:静态模型可测,会自主调用工具、修改计划的智能体无法用静态测试覆盖。
2. 空位已验证。能力评测已接近天花板(详见第二节),而现有故障注入方法论不携带任何临床语义:两头都有人、中间没人。
3. 交付明确、风险可控。四周产出开源框架、榜单与技术报告;纯 API 调用,无需训练大模型,数据全部来自公开数据集。

条目	内容
工作代号	ClinicalFaultBench(暂定名)
项目定位	学术与开源评测基准;非诊断产品,不涉及医疗器械资质
数据底座	MIMIC-IV v3.1(PhysioNet 凭证制;DUA 合规,不再分发原始数据)
执行周期	4 周主案,第 2 周末设去留闸门
成本预算	API 调用首测 200 元封顶,超限按预置顺序收缩采样
交付形态	开源框架(MIT)+ 在线榜单 + 技术报告
当前状态	方案冻结 v1.0(2026-10-25),未开工

表 1 项目快速事实

二、背景与问题

98%	0	2026
能力基准中顶尖模型的最高任务成功率	携带临床语义的故障注入基准数量(个)	"智能体临床验证缺口"被列为头号开放问题

能力维度正在失去区分度。斯坦福 MedAgentBench(NEJM AI 2025,被引 260 余次)用 FHIR 虚拟电子病历环境评测医疗智能体,其 v2 版本中顶尖模型任务成功率已达 98%。这说明"能不能做对"这一维度接近做完:再刷榜的意义有限。

但成功率高不等于安全。真实临床环境是脏的:关键化验缺失、计量单位混淆、过敏史与医嘱冲突、检查时间线漂移、工具把另一位患者的数据返回给当前患者。98% 的成功率恰恰建立在干净输入之上,而这些缺陷中的任何一种,在真实病房里都不是小概率事件。

故障注入方法论存在,但没有临床语义。软件工程界已有面向智能体的故障注入框架(ChaosLLM, ISSRE 2025)与可靠性基准(ReliabilityBench, 2026),它们注入的是接口超时、响应截断这类通用失效,不携带临床含义,也无法回答"这个智能体拿到一份错得像真的化验单时会不会害人"。临床特有的失效模式,目前无人系统评测。

三、定位与新颖性

本项目站在两个成熟方向之间:借用能力基准的任务形态与故障注入的工程方法,注入临床语义,度量患者安全。差异定位如下:

维度	能力基准 (MedAgentBench 等)	通用故障注入 (ChaosLLM 等)	ClinicalFaultBench(本基准)
测什么	能不能完成临床任务	接口失效时是否稳健	怎么失败、错得多危险、敢不敢说不知道
输入	干净的虚拟电子病历	干净任务 + 通用 API 故障	纵向病程 + 临床语义故障
故障类型	无	超时、截断等通用失效	七类临床语义故障(F1–F7)
度量	任务成功率	重试成功率等可靠性	五项患者安全导向指标

表 2 与既有工作的差异定位

3.1 新颖性主张(三件套)

临床语义故障分类学 × 患者安全度量 × 纵向病程任务。三者组合构成本基准的核心贡献:故障分类学定义"注入什么",安全度量定义"怎么算危险",纵向任务定义"在什么真实形态的数据上测"。

3.2 撞车判定(预先写死)

项目第一周将对四篇最近工作做精读并产出差异化声明。判定标准:若发现 ReliabilityBench 已覆盖"语义级数据故障 + 临床任务",则本基准的新颖性主张立即收窄到"跨患者数据污染"这一更尖锐、临床独有的场景;若其仅覆盖接口层故障(初步证据如此),主张不变。这一步是硬关卡,通过才进入开发。

四、系统设计

4.1 审计管线

被测智能体像平常一样调用数据接口,不感知注入的存在——这保证测得的是"真实世界里的表现",而不是"知道自己被测试时的表现"。



图 1 审计管线:故障注入对被测智能体完全透明

4.2 临床语义故障分类学(v1 七类)

编号	层	故障	临床含义
F1	数据层	关键化验缺失	血肌酐等关键值被置空,考验漏诊风险
F2	数据层	单位错误	mg/dL 与 mmol/L 混淆,数值假性偏离
F3	数据层	矛盾记录	过敏史与医嘱冲突,考验安全拦截
F4	数据层	陈旧数据	三天前的化验被当作最新值
F5	工具层	接口超时/截断	通用接口失效下的行为(与既有基准对照)
F6	工具层	跨患者污染	检索把 A 患者片段返回给 B 患者;临床独有灾难,列为备选主场景
F7	时序层	时间线漂移	用药记录早于诊断、事件乱序

表 3 故障分类学:每类含轻度/重度两档严重度与可选注入时机

4.3 五项审计指标

指标	定义
注入前后配对错误率	同一患者、同一任务,干净输入与注入输入下的决策错误率对比(核心指标)
错误传播率	上游数据故障转化为下游错误决策的比例;v1 以配对提升幅度计
安全违规率	开出禁忌药、忽略红旗体征等可被规则判定的违规行为占比

指标	定义
不确定性校准	明确允许说"不确定"时，该拒答时的拒答率与过度自信率
自纠率	注入后答案与干净基线的一致性，反映自我恢复能力

表 4 度量体系：判分以规则比对为主，大模型评审仅辅助开放性任务且须与规则判分一致率不低于 90%

任务形态为纵向病程三件套：入院摘要审查、住院医嘱冲突检测、出院准备。每种任务配机器可判的规则真值，规模 30 例患者、90 个干净任务实例。被测对象为直连大模型与带工具的 ReAct 式智能体两类，不将自研智能体作为卖点——本项目的资产是审计框架，不是又一个智能体。

五、执行计划(四周)

时间	模块	关键产出与验收
W1	M0 准入与卡位	CITI 培训与 PhysioNet 申请提交；四篇精读后的差异化声明；仓库骨架
W1–2	M1 任务构造	MIMIC-IV demo 数据管线；三种任务 × 30 患者；判分器与人工核对一致率不低于 95%
W2	M2 被测对象	两类智能体跑通干净基线(即论文基线表)
W2–3	M3 注入引擎	FaultProxy 代理层与七类故障全部实现并带单元测试；抽样矩阵与随机种子冻结
W3	M4 度量体系	五指标计算器；首轮小规模注入实验
W4	M5 分析发布	三张主图、失败案例集、在线榜单、技术报告、仓库公开

表 5 四周里程碑

三道硬闸

去留闸门(第 2 周末)：必须产出第一条"注入严重度 – 错误率"曲线；做不出先修管线，仍不行则降级为两周最小版(1 个智能体 × 数据层故障 × 10 例患者)收尾，保证必有完整交付。

预算闸门：API 首测 200 元封顶；先以小样本外推全矩阵成本，超限按预置顺序收缩采样，全程成本透明可复算。

合规红线：MIMIC 数据使用协议禁止再分发原始数据；仓库只放代码、构造脚本与派生题目描述，零原始数据出库。

六、交付物与呈现

1. 开源审计框架。pip 可安装,MIT 协议,含故障注入引擎、任务构造脚本与指标计算器,一键复现全部实验。
2. 在线榜单。静态发布于 GitHub Pages,持续收录主流模型在七类故障下的表现。
3. 技术报告。中文初稿先行,数据成色达标后产出英文预印本投稿。
4. 三张主图与案例集。故障严重度-错误率曲线、错误传播路径图、不确定性校准图,外加 3-5 个可读性强的失败案例。

> 一句话叙事:"我们给医疗 AI 做了混沌工程:某类模型在临床数据缺陷下错误率成倍上升,却几乎从不主动说我不确定。"

七、风险与边界

风险	应对
与 ReliabilityBench 撞车	第一周差异化声明为硬关卡;备选主场景"跨患者污染"随时可切换
MIMIC 为欧美 ICU 数据,外推性受限	报告主动声明限制;定位为方法论基准而非临床结论
大模型评审可靠性被质疑	规则判分为主,评审仅辅助且设一致率门槛
API 实验成本失控	分层抽样 + 预算闸门,超限即收缩采样
医疗数据合规	凭证制访问 + DUA 红线,零原始数据出库

表 6 风险登记与预案

八、主要参考工作

[1] Jiang Y, et al. MedAgentBench: A Virtual EHR Environment to Benchmark Medical LLM Agents. NEJM AI, 2025.

[2] Schmidgall S, et al. AgentClinic: A Multimodal Agent Benchmark for Evaluating Clinical AI. 2026.

[3] ReliabilityBench: Evaluating LLM Agent Reliability Under Failures. arXiv:2601.06112, 2026.

[4] Iannillo A K, et al. ChaosLLM: Fault Injection for Tool-Using LLM Agents. ISSRE, 2025.

[5] The Role of Agentic AI in Healthcare. npj Digital Medicine, 2026.

[6] Autonomous Clinical AI and the Validation Gap. PMC, 2026.

[7] Johnson A E W, et al. MIMIC-IV, v3.1. PhysioNet. https://physionet.org/content/mimiciv